

# **DERİN ÖĞRENME TABANLI**

## **ENDÜSTRİYEL ANORMALLİK TESPİTİ:**

### **METAL SOMUN UYGULAMASI**

**Ders:** Derin Öğrenme

**Öğrenci:** Ahmet Taha Aktürk - 23120205026

**Tarih:** 13.12.2025

# 1. PROJE KONUSU VE ÖNEMİ

## 1.1. Projenin Tanımı ve Seçilme Gerekçesi

Bu projenin temel amacı, endüstriyel üretim bandındaki kalite kontrol süreçlerini otomatize ve optimize etmek için bilgisayarlı görüp derin öğrenme tekniklerini kullanmaktadır. Projemizde, üretimde sıkılıkla kullanılan "Metal Somun" parçaları üzerindeki üretim hatalarını (ezilme, çizik, renk bozulması vb.) tespit edebilen bir yapay zeka modeli geliştirilmiştir.

**Seçilme Gerekçesi:** Endüstriyel üretimde kalite kontrol, geleneksel olarak insan operatörler tarafından görsel inceleme yoluyla yapılmaktadır. Ancak bu yöntem:

- Yavaştır ve üretim hızını sınırlar.
- İnsan faktörüne bağlı olduğu için yorgunluk ve dikkat dağınlığı sonucu hatalara açıktır.
- Sürdürülebilir ve ölçülebilir değildir.

Bu nedenlerle, insan gözünün hassasiyetini taklit eden ve hatta onu aşan otomatik sistemlere ihtiyaç duyulmaktadır. Seçilen projemiz, **Endüstri 4.0 ve Akıllı Fabrikalar** konseptinin temel taşılarından biri olan "Hatasız Üretim" hedefine doğrudan hizmet etmektedir.

## 1.2. İlgili Alanın Önemi ve Literatür Özeti

Anormallik tespiti (Anomaly Detection), makine öğrenmesi alanında kritik bir yere sahiptir. Özellikle "Denetimsiz Öğrenme" (Unsupervised Learning) yaklaşımları bu alanda ön plana çıkmaktadır. Çünkü fabrikalarda "hatalı" ürün verisi toplamak zordur; üretim hatları genelde kusursuz (%99 sağlam) ürün üretir. Bu yüzden modelin sadece "sağlam" (good) görüntüleri öğrenerek, daha önce hiç görümediği hataları ayırt etmesi gerekmektedir.

Literatürde bu problem için daha önce:

1. **Autoencoder (Oto-kodlayıcılar):** Görüntüyü sıkıştırıp tekrar oluşturmaya çalışır. Hatalı kısımlar iyi oluşturulamaz ve fark alınarak hata bulunur. Ancak görüntülerde bulanıklık sorunu yaşanır.
2. **GAN (Çekişmeli Üretici Ağları):** Eğitimleri zordur ve kararsızlık (instability) sorunları vardır.

Bu projede ise literatürdeki en güncel ve başarılı yöntemlerden biri olan, özellik tabanlı bellek bankası (Memory Bank) yaklaşımı benimsenmiştir. Ayrıca kullandığımız algoritma ve pre-trained modeller sadece anomaliyi tespit etmekle kalmaz kullandığımız ısı haritalarıyla anomalinin nerede olduğunu da gösterir bu da operatör ekibinin işini daha da kolaylaştırır.

## 2. VERİ SETİNİN BELİRLENMESİ

### 2.1. MVTec AD Veri Seti

Projede, endüstriyel anormallik tespiti alanında akademik standart kabul edilen **MVTec AD (MVTec Anomaly Detection)** veri seti kullanılmıştır. Bu veri seti, üretim senaryolarını simüle eden yüksek çözünürlüklü görüntülerden oluşur. Metal Somun dışında bulunan başlıca ürün datasetleri:

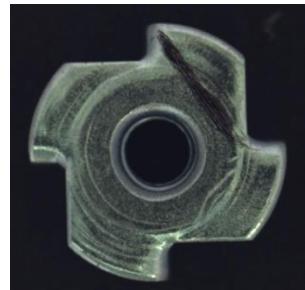
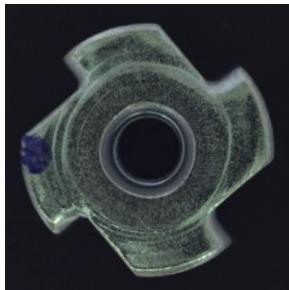
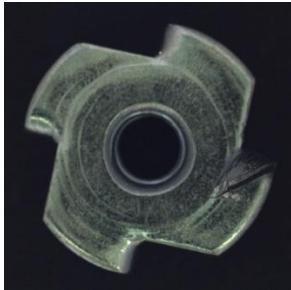
- Hali
- Hap
- Kablo

### 2.2. Metal Somun (Metal Nut) Veri Seti Özellikleri

MVTec veri seti içerisinde Metal Somun alt veri kümesi seçilmiştir.

- **Eğitim Verisi (Train Set):** Sadece "Good" (Sağlam) olarak etiketlenen kusursuz somun fotoğraflarını içerir. Modele sadece bunları göstererek "normalin ne olduğunu" öğrettiğimizde.
- **Test Verisi (Test Set):** Hem sağlam somunları hem de çeşitli anormallik türlerini içerir.
  - **Anormallik Türleri:**
  - Eğiklik (Bent)
  - Renk Atması (Color)
  - Çizik (Scratch)
  - Ters Çevirme (Flip)
- **Yer Gerçeği (Ground Truth):** Test setindeki hatalı görüntülerin, hatanın tam olarak nerede olduğunu piksel piksel gösteren siyah-beyaz maske görüntüleri mevcuttur. Test aşamasında model tahminini veri setimizin bu kısmıyla karşılaştırır.

**Veri Seti Yapısı:** Veri seti klasör yapısı aşağıdaki gibi düzenlenmiştir ve kod içerisinde otomatik olarak işlenmektedir:



## 3. YÖNTEM VE ALGORİTMA SEÇİMİ: PATCHCORE

### 3.1. Neden PatchCore?

Bu projede **PatchCore** algoritması tercih edilmiştir. Diğer yöntemlere (Autoencoder, GAN) göre üstünlükleri şunlardır:

- Yüksek Başarım:** MVTec AD veri setine en uygun yöntemlerden biridir.
- Hızlı Eğitim:** Derin bir ağı sıfırdan eğitmek yerine, önceden eğitilmiş (Pre-trained) ağların özelliklerini kullanır (Eğitim süresi dakikalar içerisinde sonlanır).
- Yerelleştirme Yeteneği:** Hatanın sadece varlığını değil, görüntü üzerindeki tam konumunu (segmentasyon) da yüksek doğrulukla bulur.

### 3.2. Algoritmanın Çalışma Mantığı

PatchCore algoritması şu adımları izler:

- Özellik Çıkarımı:** ResNet50 gibi güçlü bir ağı kullanılarak görüntünün farklı katmanlarından öznitelikler (features) çıkarılır.
- Bellek Bankası (Memory Bank):** Eğitim setindeki (sağlam) görüntülerin öznitelikleri bir havuzda toplanır.
- Coreset Örneklemesi:** Bellek çok şişmesin diye, veriyi en iyi temsil eden noktalar seçilerek veri boyutu küçültülür.
- Anormallik Tespiti:** Test görüntüsünden gelen parçalar (patch), hafızadaki en yakın "sağlam" parçayla karşılaştırılır (k-Nearest Neighbors). Aradaki mesafe ne kadar büyüğse, o bölge o kadar "anormaldir".

## 4. DENEYSEL SONUÇLAR VE ANALİZ

Model, Metal Somun veri seti üzerinde eğitilmiş ve test edilmiştir. Anormallik tespiti performansı AUROC metriği ile ölçülmüştür.

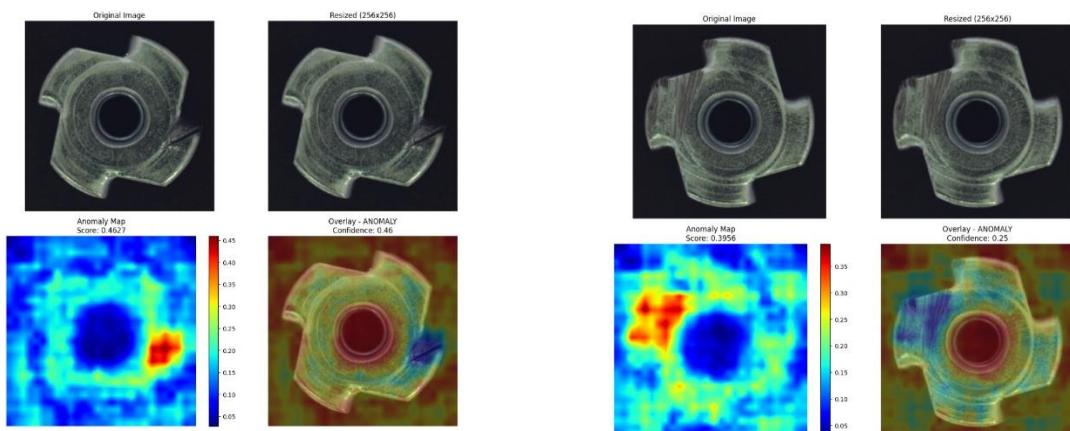
### 4.1. Başarım Metrikleri

Elde edilen sonuçlar, modelin sağlam ve hatalı ürünleri birbirinden yüksek başarıyla ayırdığını göstermektedir. 115 test verisinde yalnızca iki fire verilmiştir. Başarım Metriklerine göz attığımızda veri setinin ne kadar temiz olduğu ve kullandığımız model ve algoritmanın veri setine ne kadar uyumlu olduğunu görmekteyiz.

```
--- Model Performans Raporu ---
Optimal Anomali Eşiği: 0.3093
AUROC Score: 0.9976
F1 Score : 0.9892
Accuracy : 0.9826
Precision : 0.9892
Recall    : 0.9892
```

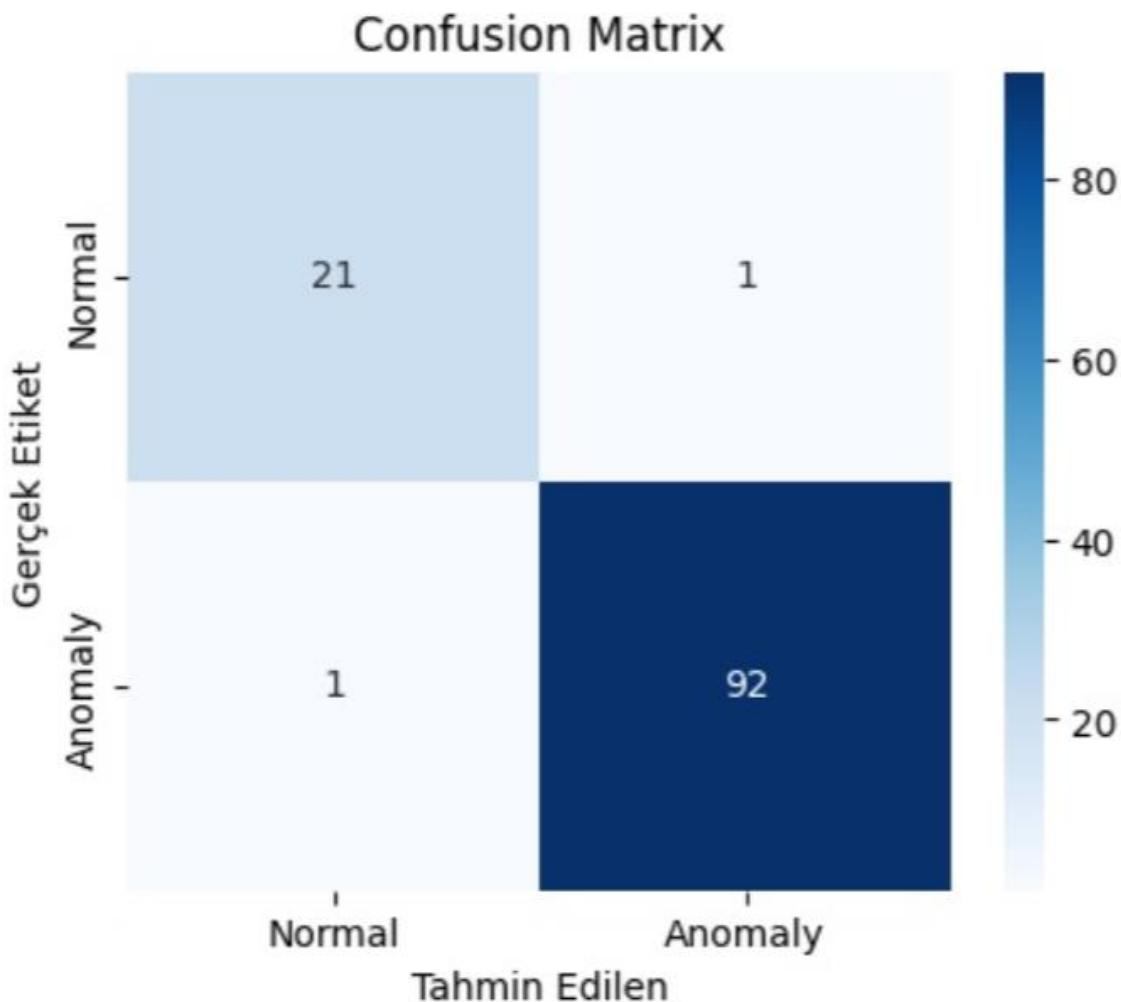
### 4.2. Görsel Sonuçlar ve Hata Haritaları

Aşağıdaki görsellerde, modelin tespit ettiği hatalar ve oluşturduğu "Isı Haritaları" (Heatmaps) görülmektedir. Kırmızı alanlar, modelin anormallik tespit ettiği bölgeleri temsil eder.



### 4.3. Karmaşıklık Matrisi (Confusion Matrix)

Modelin sınıflandırma performansının detayı aşağıdaki matriste verilmiştir. Matris, kaç adet sağlam ürünün yanlışlıkla hatalı olarak işaretlendiğini (False Positive) veya kaç hatanın kaçırıldığını (False Negative) gösterir.



## 5. SONUÇ

Bu projede, derin öğrenme tabanlı PatchCore yaklaşımı kullanılarak metal somunlar üzerinde bir kalite kontrol sistemi geliştirilmiştir. MVTec veri seti üzerinde yapılan testler sonucunda, yöntemin anormal üretimlerin az olması nedeniyle endüstriyel standartları karşılayacak düzeyde yüksek doğruluk oranlarına ulaştığı gözlemlenmiştir. Geliştirilen sistem, insan müdahalesini en aza indirerek üretim verimliliğini artırma potansiyeline sahiptir.